

Построение пайплайнов и визуализация потоков данных в Airflow

Урок 7





План курса (вертикальный)

1 Модели данных и нормализация таблиц. Схема "звезда".

Прошедший урон

Введение в подготовку данных для аналитиков. Таблицы фактов и таблицы измерений.

Прошедший урон

Получение денормализованных таблиц из нормализованных.

Прошедший урон

Партицирование данных.

Сегодняшний урон

Обзор возможностей Airflow, установка и настройка.

Будущий урок

Операторы в Airflow и их применение для ETL.

Будущий урок

Построение пайплайнов и визуализация потоков данных в Airflow.

Будущий урок

Специфика применения ETL в различных предметных сферах

Будущий урок



Что будет на уроке сегодня

X

Построение полного цикла ETL



Викторина



Могут ли быть циклы в Airflow DAG?

- 1. Да могут
- 2. Нет, DAG просто не будет выполняться если в нем будут циклы



Могут ли быть циклы в Airflow DAG?

- 1. Да могут
- 2. Нет, DAG просто не будет выполняться если в нем будут циклы



Параметр catchup=False в объявлении DAG говорит о

- 1. Том что наш граф должен определенным образом отлавливать ошибки
- 2. Расписание не будет учитываться при работе DAG
- 3. Airflow не может запускать DAG до указанной даты



Параметр catchup=False в объявлении DAG говорит о

- 1. Том что наш граф должен определенным образом отлавливать ошибки
- 2. Расписание не будет учитываться при работе DAG
- 3. Airflow не может запускать DAG до указанной даты



Правильный порядок приоритетов для задач?

- 1. Значения в default_args -> значение оператора по умолчанию -> явно переданные аргументы
- 2. Явно переданные аргументы -> значения в default_args -> значение оператора по умолчанию
- 3. Явно переданные аргументы -> значение оператора по умолчанию -> значения в default_args



Правильный порядок приоритетов для задач?

- 1. Значения в default_args -> значение оператора по умолчанию -> явно переданные аргументы
- 2. Явно переданные аргументы -> значения в default_args -> значение оператора по умолчанию
- 3. Явно переданные аргументы -> значение оператора по умолчанию -> значения в default_args



Что такое DAG?

- 1. Пайплайн для Airflow
- 2. Направленный ацикличный граф описывающий пайплайн



Какой блок описывает команды в Jinja?

- 1. {}
- 2. {{}}
- 3. {%%}
- 4. {{\%\%}}



Какой блок описывает команды в Jinja?

- 1. {}
- 2. {{}}
- 3. <mark>{%%</mark>}
- 4. {{\%\%}}



Какой блок описывает параметры в Jinja?

- 1. {}
- 2. {{}}
- 3. {%%}
- 4. {{\%\%}}



Какой блок описывает параметры в Jinja?

- **1.** {
- 2. {{
- 3. {%%}
- 4. {{\%\%}}



С помощью какого атрибута можно добавить документацию к таску?

- 1. doc
- 2. doc_md
- 3. documentation



С помощью какого атрибута можно добавить документацию к таску?

- 1. doc
- 2. doc_md
- 3. documentation



С помощью какого атрибута можно добавить документацию к пайплайну?

- 1. doc
- 2. doc_md
- 3. documentation



С помощью какого атрибута можно добавить документацию к пайплайну?

- 1. doc
- 2. doc_md
- 3. documentation









Вопросы?

Вопросы?









Практика



Задание 1

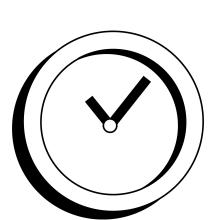
Создайте новый пайплайн. Скачайте файл ССЫЛКА. Сделайте пайплайн который будет читать файл, выполнять удаление дубликатов и загружать очищенные данные в базу данных postgress после этого отправлять письмо с количеством записей добавленных в базу данных,





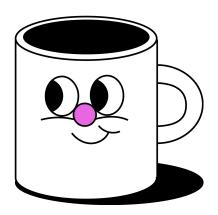
Задание 1

<<40:00->> Создайте новый пайплайн. Скачайте файл ССЫЛКА. Сделайте пайплайн который будет читать файл, выполнять удаление дубликатов и загружать очищенные данные в базу данных postgress после этого отправлять письмо с количеством записей добавленных в базу данных,





Перерыв



<<5:00->>



Задание 2

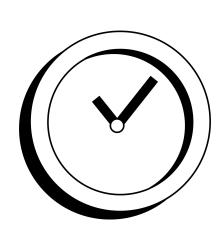
Скачайте файл ССЫЛКА. Измените пайплайн так чтобы он читал файл, выполнять удаление дубликатов и загружать недостающие данные в базу данных postgress после этого отправлять письмо с количеством записей добавленных в базу данных, но только в случае если данные были добавлены.





Задание 2

<<30:00->> Скачайте файл ССЫЛКА. Измените пайплайн так чтобы он читал файл, выполнять удаление дубликатов и загружать недостающие данные в базу данных postgress после этого отправлять письмо с количеством записей добавленных в базу данных, но только в случае если данные были добавлены.











Вопросы?

Вопросы?









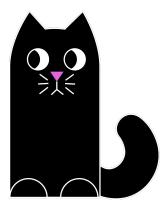
Домашнее задание



Домашнее задание

На основе сайта <u>yandex.ru</u>:

- Определите, на каком протоколе работает сайт.
- Проанализируйте структуру страницы сайта
- Внесите не менее 10 изменений на страницу с помощью инструмента разработчика и представьте скриншоты было/стало.
- Создайте прототип низкой детализации (дополнительное задание, если на семинаре дошли до задания №8)





Спасибо за внимание

